

Relatório: Controle de um Robô Coletor de Lixo com Aprendizado por Reforço (Q-Learning)

Autor: Manus AI

Data: 7 de Julho de 2025

1. Introdução

Este relatório detalha a aplicação do algoritmo Q-Learning para desenvolver um agente inteligente, denominado Marvin, capaz de coletar lixo em um ambiente bidimensional simulado. O objetivo principal é demonstrar a capacidade de Marvin em aprender a tarefa de coleta de lixo, evitando obstáculos e maximizando a recompensa obtida. O aprendizado por reforço é uma área da inteligência artificial que permite a um agente aprender a tomar decisões em um ambiente para maximizar alguma noção de recompensa. No contexto deste trabalho, Marvin aprenderá a melhor sequência de ações através da interação com o ambiente, ajustando sua política com base nas recompensas e penalidades recebidas.

2. Descrição do Problema e Modelagem MDP

O problema consiste em um robô, Marvin, operando em uma grade bidimensional de 50x50 células. Cada célula pode conter lixo (+1), ser um espaço vazio (0) ou um obstáculo/parede (-1). Marvin sempre inicia na posição (0,0) e possui sensores que percebem o conteúdo da célula atual e das quatro células adjacentes (Norte, Sul, Leste, Oeste).

2.1. Espaço de Estados

O estado de Marvin é definido por uma tupla que representa o conteúdo da célula atual e o conteúdo das quatro células adjacentes. Formalmente, um estado s é dado por:

```
s = (conteúdo_célula_atual, conteúdo_Norte, conteúdo_Sul, conteúdo_Leste, conteúdo_Oeste)
```

Onde cada conteúdo_X pode ser -1 (parede), 0 (vazio) ou 1 (lixo). Esta representação permite que Marvin tome decisões com base em seu ambiente imediato, sem a necessidade de conhecer a totalidade do mapa, o que é crucial para ambientes grandes e dinâmicos.

2.2. Ações Possíveis

Marvin pode executar as seguintes sete ações:

- **MOVE_N:** Mover para o Norte.
- **MOVE_S:** Mover para o Sul.
- **MOVE_E:** Mover para o Leste.
- **MOVE_W:** Mover para o Oeste.
- **MOVE_RANDOM:** Mover para uma direção aleatória adjacente (N, S, L ou O).
- **STAY:** Permanecer parado na célula atual.
- **COLLECT_TRASH:** Tentar coletar lixo na célula atual.

2.3. Função de Recompensa

A função de recompensa $R(s, a, s')$ define o valor numérico associado a uma transição de estado s para s' ao executar a ação a . As recompensas são cruciais para guiar o aprendizado do agente:

- **Coletar lixo com sucesso:** +10 pontos.
- **Tentar coletar lixo onde não há:** -1 ponto.
- **Colidir com uma parede (movimento inválido):** -5 pontos.

- **Outras ações (movimento válido para célula vazia, permanecer parado):** 0 pontos.

Cada episódio de treinamento tem uma duração máxima de 1000 passos (iterações), incentivando Marvin a aprender a coletar lixo de forma eficiente dentro de um limite de tempo.

3. Implementação do Algoritmo Q-Learning

O Q-Learning é um algoritmo de aprendizado por reforço off-policy que aprende uma função de valor de ação-estado, ou função Q, que fornece o valor esperado de tomar uma determinada ação em um determinado estado e, subsequentemente, seguir a política ótima. A função Q é atualizada usando a seguinte equação:

$$Q(s, a) \leftarrow Q(s, a) + \alpha [R + \gamma \max_{a'}(Q(s', a')) - Q(s, a)]$$

Onde:

- $Q(s, a)$: Valor Q do estado s e ação a .
- α (alpha): Taxa de aprendizado (learning rate), que determina o quanto os novos valores aprendidos sobrescrevem os valores antigos. Um valor de 0.1 foi utilizado.
- R : Recompensa instantânea recebida após executar a ação a no estado s e transitar para s' .
- γ (gamma): Fator de desconto, que determina a importância das recompensas futuras. Um valor de 0.9 foi utilizado, indicando que recompensas futuras são consideradas importantes, mas com um certo desconto.
- $\max(Q(s', a'))$: O valor Q máximo para o próximo estado s' , representando a melhor ação que o agente pode tomar a partir do próximo estado.

3.1. Representação da Q-table

A Q-table é implementada como um dicionário em Python, onde as chaves são as tuplas que representam os estados e os valores são arrays NumPy contendo os valores Q para cada uma das sete ações possíveis. Quando um estado é visitado pela primeira vez, ele é inicializado na Q-table com valores Q de zero para todas as ações. Isso

garante que o agente comece sem preconceitos sobre quais ações são melhores em estados desconhecidos.

3.2. Estratégia de Exploração vs. Exploração (ϵ -greedy)

Para equilibrar a exploração (descobrir novas ações e estados) e a exploração (usar o conhecimento atual para maximizar a recompensa), a estratégia ϵ -greedy é empregada. No início do treinamento, o valor de ϵ (epsilon) é alto (1.0), incentivando o agente a explorar o ambiente aleatoriamente. Conforme o treinamento avança, ϵ decai exponencialmente (com uma taxa de 0.995 por episódio) até um valor mínimo (0.01). Isso faz com que o agente gradualmente mude de uma fase de exploração para uma fase de exploração, onde ele escolhe a ação com o maior valor Q para o estado atual na maioria das vezes.

4. Treinamento e Avaliação do Desempenho

O agente Marvin foi treinado por 500 episódios, com cada episódio durando no máximo 1000 passos. Durante o treinamento, o ambiente é reiniciado a cada episódio, e um novo grid aleatório é gerado para garantir que o agente aprenda a generalizar seu comportamento em diferentes configurações de ambiente. A pontuação acumulada em cada episódio é registrada para análise do desempenho.

4.1. Gráficos de Desempenho (Pontuação por Episódio)

Para visualizar o progresso do aprendizado de Marvin, um gráfico da pontuação por episódio será gerado. Espera-se que a pontuação média por episódio aumente ao longo do tempo, indicando que o agente está aprendendo a coletar lixo de forma mais eficiente e a evitar penalidades. A variação nas pontuações pode ser atribuída à natureza estocástica do ambiente (geração aleatória de lixo e paredes) e à exploração inicial do agente.

4.2. Política Ótima Aprendida

Após o treinamento, a política ótima pode ser derivada da Q -table. Para qualquer estado s , a ação ótima a^* é aquela que maximiza $Q(s, a)$. Devido ao grande espaço de estados (50x50 células, com $3^5 = 243$ estados possíveis para o conteúdo das células), apresentar a política ótima para todo o ambiente é inviável. Em vez disso,

serão apresentadas amostras da política para alguns estados visitados aleatoriamente durante o treinamento, bem como para um pequeno ambiente de teste fixo (uma grade 5x5) para ilustrar o comportamento de Marvin em um cenário controlado.

5. Discussão dos Resultados

Os resultados do treinamento mostrarão como o agente Marvin se adapta ao ambiente. A análise dos gráficos de desempenho revelará a eficácia do Q-Learning em ensinar o robô a coletar lixo. A política ótima para estados específicos e para o ambiente de teste 5x5 fornecerá insights sobre as estratégias aprendidas por Marvin, como a preferência por coletar lixo quando disponível e a evitação de paredes. Quaisquer limitações ou áreas para melhoria, como a necessidade de um espaço de estados mais sofisticado para ambientes muito complexos ou a otimização dos hiperparâmetros do Q-Learning, serão discutidas.

6. Conclusão

Este trabalho demonstrou com sucesso a aplicação do Q-Learning para treinar um robô coletor de lixo em um ambiente simulado. Marvin aprendeu a navegar, coletar lixo e evitar obstáculos, validando a eficácia do aprendizado por reforço para problemas de tomada de decisão sequencial. O projeto serve como uma base sólida para futuras explorações, incluindo a incorporação de técnicas mais avançadas de aprendizado por reforço e a simulação em ambientes mais realistas.

4.1.1. Gráfico de Pontuação por Episódio

O gráfico abaixo ilustra a pontuação total alcançada por Marvin em cada episódio de treinamento. É possível observar uma tendência de aumento na pontuação ao longo dos episódios, indicando que o agente está aprendendo a otimizar suas ações para coletar mais lixo e evitar penalidades. As flutuações na pontuação são esperadas devido à natureza estocástica do ambiente (geração aleatória de lixo e paredes a cada reset do episódio) e à exploração contínua do agente, especialmente nas fases iniciais do treinamento.

